ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ
ВЫСШЕГО ОБРАЗОВАНИЯ
«НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
«ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»

Факультет информатики, математики и компьютерных наук

Программа подготовки бакалавров по направлению
01.03.02 Прикладная математика и информатика

Спасюк Мария Ильинична

КУРСОВАЯ РАБОТА

Проверка гипотезы повторности выборки

Научный руководитель
д.ф.-м.н., к.т.н., с.н.с.
П.А. Колданов

Нижний Новгород, 2025

Содержание

Введение **3**

1. ГЛАВА 1. Теоретическая часть **4**

1.1. Основные понятия 4

1.2. Точный тест на случайность в непараметрическом случае на основе сериальной корреляции 6

1.3. Ранговый тест фон Неймана для проверки повторности выборки 13

1.4. Тест серий 16

1.5. Критерий инверсий 21

2. ГЛАВА 2. Практическая часть **23**

2.1. Определение альтернатив и генерация данных 23

2.2. Подсчет мощности тестов и ее сравнение 23

2.3. Применение тестовых процедур на данных фондового рынка 40

Заключение **46**

Список литературы **47**

Приложение **49**

Введение

Проверка гипотезы о повторности выборки является важной задачей математической статистики, связанной с анализом случайных последовательностей. Процедуры проверки выборки на повторность позволяют определять наличие таких скрытых закономерностей в данных, как линейные тренды, периодичность, автокорреляция и др. Тесты проверки повторности выборки применяются в экономике для анализа временных рядов, например, для анализа динамики цен акций на фондовом рынке. Также данные статистические тесты позволяют анализировать процесс производства и следить за контролем качества производимой продукции. Кроме того, процедуры проверки выборки на повторность также широко применяются в медицине для обнаружения закономерностей в клинических экспериментах. В курсовой работе рассматриваются тест на основе сериальной корреляции (Wald, A., Wolfowitz, J.), ранговая версия теста фон Неймана (Bartels, R.), тест серий (Levene, H.), а также критерий инверсий против различных альтернатив (линейный тренд в данных, периодичность, положительная автокорреляция первого порядка).

Цель работы: определить, при какой частоте наблюдений за доходностями акций данные можно рассматривать как повторную выборку.

Задачи:

1. сделать обзор существующих процедур проверки гипотезы выборки на повторность;
2. сравнить тесты по мощности;
3. применить тесты к данным о доходностях акций фондового рынка;

1. ГЛАВА 1. Теоретическая часть

1.1 Основные понятия

Определение 1. *Выборкой объема n из распределения случайной величины X называется случайный вектор $(X_1, X_2, \ldots, X_n)^\top$, где распределение X_i для всех $i = 1, \ldots, n$ совпадает с неизвестным распределением $F_X(x)$.*

Определение 2. *Выборка $X_1, X_2, \ldots, X_n$ объема n называется повторной, если $X_1, X_2, \ldots, X_n$ — независимые одинаково распределенные случайные величины.*

Определение 3. *Вариационный ряд — упорядоченная выборка (обычно по возрастанию):*

$$x_{(1)} \leq x_{(2)} \leq \cdots \leq x_{(n)},$$

где $x_{(1)}$ — наименьшее значение в выборке, а $x_{(n)}$ — наибольшее значение в выборке.

Определение 4. *Ранг наблюдения — порядковый номер наблюдения в вариационном ряду. Обозначается буквой R, R_i — ранг i-го наблюдения в выборке.*

Возможны два случая:

1. *Выборка не содержит повторяющихся значений. Тогда ранг — просто его порядковый номер в упорядоченной выборке.*

2. *Выборка содержит повторяющиеся значения. Тогда используется средний ранг — среднее арифметическое позиций этих значений в вариационном ряду.*

Пример: Дана выборка из 7 наблюдений: $6, 1, 2, 7, 8, 2, 100$. Вариационный ряд: $1, 2, 2, 6, 7, 8, 100$. Для двоек: позиции 2 и 3. Средний ранг: $\frac{2+3}{2} = 2.5$. Тогда:

$$R_1 = 4, \quad R_2 = 1, \quad R_3 = 2.5, \quad R_4 = 5, \quad R_5 = 6, \quad R_6 = 2.5, \quad R_7 = 7.$$

Определение 5. *Ковариация двух случайных величин X_i и X_j определяется следующим образом:*

$cov(X_i, X_j) = \sigma_{ij} = E((X_i - EX_i)(X_j - EX_j)) = \sum_k \sum_l (x_k - EX_i)(x_l - EX_j)P(X_i = x_k, X_j = x_l)$

Определение 6. *Матрица*

$$\begin{pmatrix} \sigma_{11} & \sigma_{12} & \dots & \sigma_{1N} \\ \sigma_{21} & \sigma_{22} & \dots & \sigma_{2N} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{N1} & \sigma_{N2} & \dots & \sigma_{NN} \end{pmatrix}$$

где $\sigma_{ij} = \mathrm{cov}(X_i, X_j)$, называется ковариационной матрицей вектора $(X_1, \dots, X_N)^T$. Очевидно,

$$\sigma_{ij} = \sigma_{ji}, \quad \sigma_{ii} = DX_i$$

Определение 7. *Компоненты X_i и X_j вариационного ряда $X_{(1)} < X_{(2)}$ выборки $X = (X_1, X_2, ..., X_n)$ образуют инверсию, если $i < j$, но X_i стоит правее X_j в вариационном ряду, т.е. наблюдению с меньшим номером соответствует большее значение.*

Определение 8. *Рассматриваемая как функция $\theta \in \Theta_K$, вероятность $P_\theta(\varphi = 1)$ называется мощностью теста φ. При произвольном $\theta \in \Theta$ $P_\theta(\varphi = 1)$ называется функцией мощности и обозначается $\beta_\varphi(\theta)$.*

1.2 Точный тест на случайность в непараметрическом случае на основе сериальной корреляции

Коэффициент сериальной корреляции с лагом h определяется по следующей формуле:

$$R_h = \frac{\sum_{n=1}^{N} X_n X_{h+n} - \left(\sum_{n=1}^{N} X_n\right)^2 / N}{\sum_{n=1}^{N} X_n^2 - \left(\sum_{n=1}^{N} X_n\right)^2 / N},$$

где X_{h+n} заменяется на X_{h+n-N} для всех α: $h + \alpha > N$.

На основе R_h разработана тестовая процедура такая, что:

1. если $F_X(x)$ непрерывна, размер критической области теста не зависит от кумулятивной функции распределения величин $X_1, X_2, \ldots, X_N$. Это позволяет построить точный тест значимости даже когда ничего не известно о $F_X(x)$, кроме её непрерывности;

2. если $F_X(x)$ не непрерывна, но все её моменты конечны и её дисперсия положительна, размер критической области при $N \to \infty$ приближается к значению, которое она имела бы в случае непрерывности $F_X(x)$. Таким образом, в пределе точный тест возможен и в этом случае. Случай, когда вид $F_X(x)$ неизвестен, называется непараметрическим случаем [1].

Рассмотрим статистику R_h подробнее.

Пусть x_α — наблюдаемое значение X_α ($\alpha = 1, \ldots, N$). Рассмотрим множество таких наборов $(X_1, X_2, \ldots, X_N)$, которые являются перестановками множества $(x_1, x_2, \ldots, x_N)$ наблюдаемых значений случайной величины X.

При H_0: вероятность того, что $(X_1, X_2, \ldots, X_N)$ является какой-либо конкретной перестановкой последовательности $(x_1, x_2, \ldots, x_N)$ рав-

на $\frac{1}{N!}$.

Рассмотрим множество из $N!$ значений R_h, полученных путем подстановки вместо $(X_1, X_2, \ldots, X_N)$ всех возможных перестановок множества $(x_1, x_2, \ldots, x_N)$. Вероятность получения конкретного значения R_h равна $\frac{1}{N!}$. На основе этого распределения R_h в множестве перестановок можно построить точный тест значимости.

Пусть α — заданный уровень значимости. При малых размерах выборки $N < 10$ можно придерживаться слудующей стратегии:

- В качестве критической области выбирается подмножество M значений из множества $N!$ значений R_h, где $\frac{M}{N!} = \alpha$.

- Множество M значений, составляющих критическую область, зависит в каждой конкретной задаче от возможных альтернатив случайности. Значение лага h также выбирается на основе рассматриваемых альтернатив.

Однако при больших размерах выборки данный подход вычислительно затратный, а также непрактичный, если R_h имеет одно и то же значение для нескольких перестановок множества $(x_1, x_2, \ldots, x_N)$. В таком случае критическая область, состоящая ровно из M значений R_h, может не существовать. Например, если $x_1 = x_2 = \cdots = x_N$, то все $N!$ значений R_h равны, и количество значений R_h, включенных в критическую область, должно быть либо 0, либо $N!$. Если же $F_X(x)$ непрерывна, вероятность того, что есть два равных значения R_h, равна нулю. Таким образом, когда функция распределения непрерывна, построение точного теста возможно [1].

Рассмотрим статистику $\overline{R}_h = \sum_{\alpha=1}^{N} X_\alpha X_{h+\alpha}$, где $X_{h+\alpha}$ заменяется на $X_{h+\alpha-N}$ для всех значений α, для которых $h + \alpha > N$. Так как $\sum_{\alpha=1}^{N} X_\alpha$ и $\sum_{\alpha=1}^{N} X_\alpha^2$ — константы, то статистика $\overline{R}_h$ — линейная функция R_h. Таким образом тест, основанный на $\overline{R}_h$, эквивалентен тесту, основанному на статистике R_h [1].

Так как $\overline{R}_h$ проще, чем R_h, удобнее использовать эту статистику для проверки гипотезы о повторности выборки.

Теорема 1. *(Wald A., Wolfowitz J., [1]) Если h и N взаимно простые, то совокупность T_h $N!$ значений, принимаемых $\overline{R}_h$, такая же, как T_1 — совокупность $N!$ значений, принимаемых $\overline{R}_1$. Значит, можно перейти к новой статистике:*

$$R = \sum_{n=1}^{N} X_n X_{n+1} + X_N X_1$$

Вычисление матожидания и дисперсии статистики R

Поскольку все элементы $X_1, X_2, \ldots, X_N$ независимо и одинаково распределены, можно утверждать, что:

$$E(X_1X_2) = E(X_2X_3) = \cdots = E(X_{N-1}X_N) = E(X_NX_1). \tag{1}$$

Из этого следует:

$$\begin{aligned} E(R) &= NE(X_1X_2) \\ &= \frac{N}{N(N-1)} \sum_{\alpha} \sum_{\beta \neq \alpha} X_\alpha X_\beta \\ &= \frac{1}{N-1} \left[(X_1 + \cdots + X_N)^2 - (X_1^2 + \cdots + X_N^2) \right]. \end{aligned} \tag{2}$$

Для расчета дисперсии посчитаем $E(R^2)$ [1]:

$$E(R^2) = E(X_1X_2 + \cdots + X_{N-1}X_N + X_NX_1)^2 =$$

$$= NE(X_1^2X_2^2) + 2NE(X_1X_2X_3^2) + (N^2 - 3N)E(X_1X_2X_3X_4).$$

Для любого набора положительных целых чисел $i_1, i_2, \ldots, i_k$ символ $S_{i_1 i_2 \ldots i_k}$ обозначает симметрическую функцию:

$$S_{i_1 i_2 \ldots i_k} = \sum_{\alpha_1} \sum_{\alpha_2} \cdots \sum_{\alpha_k} a_{\alpha_1}^{i_1} a_{\alpha_2}^{i_2} \cdots a_{\alpha_k}^{i_k}$$

где суммирование проводится по всем возможным наборам из k положительных целых чисел $\alpha_1, \alpha_2, \ldots, \alpha_k$ и выполняются следующие условия:

1. $\alpha_u \leq N$ для всех $u = 1, 2, \ldots, k$.

2. $\alpha_u \neq \alpha_v$ для всех $u \neq v$.

Определим часть симметрических функций:

$$S_r = X_1^r + \cdots + X_N^r.$$

- $S_1 = \sum_{i=1}^N X_i$,
- $S_2 = \sum_{i=1}^N X_i^2$,
- $S_3 = \sum_{i=1}^N X_i^3$,
- $S_4 = \sum_{i=1}^N X_i^4$.

Симметрические функции можно выразить таким образом [1]:

$$S_{11} = S_1^2 - S_2$$

$$S_{12} = S_{21} = S_1 S_2 - S_3$$

$$S_{13} = S_{31} = S_1 S_3 - S_4$$

$$S_{22} = S_2^2 - S_4$$

$$S_{111} = S_{11} S_1 - 2S_{12} = (S_1^2 - S_2) S_1 - 2(S_1 S_2 - S_3) =$$

$$= S_1^3 - 3S_1 S_2 + 2S_3$$

$$S_{112} = S_{121} = S_{211} = S_{11}S_2 - 2S_{13} =$$

$$= (S_1^2 - S_2)S_2 - 2(S_1S_3 - S_4) =$$

$$= S_1^2S_2 - S_2^2 - 2S_1S_3 + 2S_4 =$$

$$S_{1111} = S_{111}S_1 - 3S_{112} =$$

$$= S_1^4 - 3S_1^2S_2 + 2S_1S_3 - 3S_1^2S_2 + 6S_1S_3 - 6S_4 =$$

$$= S_1^4 - 6S_1^2S_2 + 8S_1S_3 + 3S_2^2 - 6S_4.$$

Используя симметрические функции, можно записать $E(R^2)$ так:

$$E(R^2) = \frac{N}{N(N-1)}S_{22} + \frac{2N}{N(N-1)(N-2)}S_{121} +$$

$$+\frac{N^2 - 3N}{N(N-1)(N-2)(N-3)}S_{111} =$$

$$= \frac{S_{22}}{(N-1)} + \frac{2S_{121}}{(N-1)(N-2)} + \frac{S_{111}}{(N-1)(N-2)}.$$

Следуя из (2) и определения симметрических функций, можно записать матожидание как

$$E(R) = \frac{1}{N-1}(S_1^2 - S_2). \tag{3}$$

Тогда дисперсия статистики R будет определяться так [1]:

$$\sigma^2(R) = E(R^2) - [E(R)]^2$$
$$= \frac{S_2^2 - S_4}{N-1} + \frac{S_1^4 - 4S_1^2S_2 + 4S_1S_3 + S_2^2 - 2S_4}{(N-1)(N-2)}$$
$$- \frac{1}{(N-1)^2}(S_1^2 - S_2)^2. \tag{4}$$

Построение теста сериальной корреляции

H_0 : $(X_1, X_2, ..., X_N)$ - повторная выборка, $F_X(x_1, x_2, ..., x_N) = F_{X_1}(x_1)...F_{X_N}(x_N)$

H_1: выборка не повторная (имеется какая-то закономерность или зависимость)

Для построения теста и вычисления мощности теста в случае малого размера выборки ($N < 10$) и альтернативы линейного тренда можно использовать подход с определением множества перестановок наблюдаемых значений и выбора критической области из M значений, как было описано выше в работе.

При выборках большого размера, которые и будут рассматриваться в практической части, данный метод становится трудно осуществимым из-за большого количества вычислений.

Вальд и Вольфовиц в [1] доказали, что при больших значениях N статистика R асимптотически распределена как нормальное.

Теорема 2. *(Wald A., Wolfowitz J., [1])*

Пусть $R(N)$ — коэффициент сериальной корреляции R, определённый как $R = \sum_{\alpha=1}^{N} X_\alpha X_{\alpha+1} + X_N X_1$, где X_1,...,X_N — случайная перестановка наблюдаемых значений $(x_1, ..., x_N)$ случайной величины X.

При $N \to \infty$, вероятность того, что $\frac{R(N)-E(R(N))}{\sigma(R(N))} < t$, стремится к пределу $\frac{1}{\sqrt{2\pi}} \int_{-\infty}^{t} e^{-\frac{x^2}{2}}\, dx$.

Тест (двусторонний) сериальной корреляции имеет вид:

$$\varphi(x_1,...,x_n) = \begin{cases} 1, & \text{если } |R'| > C_{1-\alpha/2}, \\ 0, & \text{если } |R'| \le C_{1-\alpha/2}, \end{cases}$$

где:

- $R' = \frac{R(N)-E(R(N))}{\sigma(R(N))}$;

- $C_{1-\alpha/2}$ — критическое значение из таблицы нормального распределения $N(0,1)$, такое что $P_0(|R'| > C_{1-\alpha/2}) = \alpha$;

- α — уровень значимости.

Критическая область $\mathcal{X}_1$ для теста на основе сериальной корреляции записывается так:

$$\mathcal{X}_1 = \{R : P_0(R \in \mathcal{X}_1) \leq \alpha\}$$

Алгоритм проверки выборки на повторность с помощью теста сериальной корреляции:

1. Вычислить статистику R

2. Вычислить $E(R)$ и $\sigma^2(R)$

3. Стандартировать значение R, чтобы использовать предельное нормальное распределение $N(0,1)$, по формуле

$$R' = \frac{R - E(R)}{\sigma(R)}$$

4. Задать уровень значимости α и определить $C_{1-\alpha/2}$ по таблице для $N(0,1)$, применить тест φ.

1.3 Ранговый тест фон Неймана для проверки повторности выборки

Пусть R_i — ранг i-го наблюдения в последовательности из T наблюдений. Ранговая версия коэффициента фон Неймана (RVN) задается следующим образом [2]:

$$RVN = \frac{\sum_{i=1}^{T-1}(R_i - R_{i+1})^2}{\sum_{i=1}^{T}(R_i - \bar{R})^2},$$

где $\bar{R}$ — выборочное среднее.

В предположении гипотезы H_0 в выборке нет связанных наблюдений, а значит и все ранги различны. Тогда знаменатель $\sum_{i=1}^{T}(R_i - \bar{R})^2$ является константой, равной $\frac{T(T^2-1)}{12}$. Числитель (NM) RVN равен $\sum_{i=1}^{T-1}(R_i - R_{i+1})^2$.

Если выборка повторна, то наблюдения независимы и одинаково распределены. Если перемешать наблюдения, то дисперсия и выборочное среднее останутся неизменными. Поэтому знаменатель является константой в случае повторности выборки, в отличие от числителя, который зависит от порядка наблюдений. Значит в предположении H_0 можно рассматривать числитель NM отношения RVN в качестве статистики. Однако, использование статистики NM некорректно, когда в выборке есть одинаковые элементы. В этом случае не все ранги различны, а значит знаменатель статистики RVN не является константой. В данной ситуации лучше использовать статистику RVN.

При больших значениях $T(T > 100)$ статистика RVN асимптотически распределена как $N(2, 4/T)$. Это можно установить следующим образом [2]:

$$RVN = \sum_{i=1}^{T-1}(R_i - R_{i+1})^2 \Big/ \sum_{i=1}^{T}(R_i - \bar{R})^2 =$$

$$= \sum_{i=1}^{T}(R_i - R_{i+1})^2 \Big/ \sum_{i=1}^{T}(R_i - \bar{R})^2 - (R_T - R_1)^2 \Big/ \sum_{i=1}^{T}(R_i - \bar{R})^2 =$$

(где $R_{T+1} \equiv R_1$)

$$= 2 - 2\hat{p} - (R_T - R_1)^2 \Big/ \sum_{i=1}^{T}(R_i - \bar{R})^2 \,,$$

где $\hat{p}$ — коэффициент круговой ранговой сериальной корреляции.

$$\hat{\rho} = 1 - \frac{\sum_{i=1}^{T}(R_i - R_{i+1})^2}{2\sum_{i=1}^{T}(R_i - \bar{R})^2},$$

Вальд и Вольфовиц в [1] установили, что $\sqrt{T}\hat{p}$ асимптотически распределена как $N(0,1)$.

Поскольку

$$\frac{1}{2}\sqrt{T}(RVN - 2) = -\sqrt{T}\hat{p} + \epsilon_T,$$

где

$$|\epsilon_T| = \left|\frac{1}{2}\sqrt{T}(R_T - R_1)^2 \Big/ \sum_{i=1}^{T}(R_i - \bar{R})^2\right| \leq \frac{1}{2}\sqrt{T}(T-1)^2 / \left(\frac{1}{12}T(T^2-1)\right) \to 0,$$

Поскольку $\frac{1}{2}\sqrt{T}(RVN-2) = -\sqrt{T}\hat{\rho}+\epsilon_T$, а $\epsilon_T \to 0$, то по теореме Рао [3]:

$$\frac{1}{2}\sqrt{T}(RVN - 2) \sim N(0,1).$$

Отсюда следует, что RVN асимптотически нормальна с пара-

метрами:

$$RVN \sim N\left(2, \frac{4}{T}\right).$$

Построение рангового теста фон Неймана

H_0 : $(X_1, X_2, ..., X_N)$ - повторная выборка, $F_X(x_1, x_2, ..., x_N) = F_{X_1}(x_1)...F_{X_N}(x_N)$

H_1: выборка не повторная (имеется какая-то закономерность или зависимость)

Ранговый тест (левосторонний) имеет вид:

$$\varphi(x_1, \ldots, x_n) = \begin{cases} 1, & \text{если } RVN < C_\alpha, \\ 0, & \text{если } RVN \geq C_\alpha. \end{cases}$$

- RVN — тестовая статистика;

- C_α — критическое значение, $P_0(RVN < C_\alpha) = \alpha$;

- α — уровень значимости.

В [2] приводится таблица с посчитанными критическими значениями для рангового теста в случае размера выборок $10 \leq T \leq 100$, используя аппроксимацию бета-распределением. Для выборок большего размера можно использовать аппроксимацию распределением $N(2, 4/T)$.

Алгоритм проверки выборки на повторность, используя ранговый тест:

1. Вычислить статистику RVN

2. Задать уровень значимости α и определить критическое значение C_α по таблице 2 из [2] или по таблице значений для $N(2, 4/T)$ в случае $T > 100$

3. Применить тест φ.

1.4 Тест серий

Пусть $X = (X_1, X_2, \ldots, X_n)$ — выборка объема n наблюдаемой случайной величины X, а $(x_1, x_2, \ldots, x_n)$ — её реализация.

Рассмотрим $X = (X_1, \ldots, X_n)$ с совместной функцией распределения $F_X(x_1, x_2, ..., x_n)$, предполагаемой непрерывной. Обозначим:

- Ω_n — класс всех непрерывных $F_X(x)$,
- ω_n — подкласс Ω_n, где $F_X(x) = \prod F_{X_i}(x_i)$, то есть наблюдения независимы и одинаково распределены.

Гипотеза H_0 утверждает, что $F_X(x) \in \omega_n$, то есть выборка является случайной. Предположим, что все наблюдения $(x_1, \ldots, x_n)$ различны. Построим последовательность знаков разностей: B^* — последовательность знаков (+ или −) разностей $(x_{i+1} - x_i)$ для $i = 1, \ldots, n-1$ [4].

- Восходящая серия длины p — последовательность из p подряд идущих знаков "+ не окружённая знаками "+".
- Нисходящая серия длины p — аналогично для знаков −.
- s — число восходящих серий,
- s_p — число восходящих серий длины p,
- s'_p — число восходящих серий длины больше или равной p.

Аналогично определяются t, t_p, t'_p для нисходящих серий.

- $r = s + t$ — общее число серий,
- k — общее количество знаков "+"в B^*.

При H_0:

$$E(k) = \frac{n-1}{2},$$
$$\sigma^2(k) = \frac{n+1}{12} \quad [5].$$

Для построения теста серий используется статистика отношения правдоподобия λ.

Пусть $p(\xi^{(n)} \mid F_X(x))$ — вероятность получить выборку наблюдений $\xi^{(n)}$ при условии, что $F_X(x)$ является истинным распределением. Пусть

$$p_\omega(\xi^{(n)}) = \sup_{F^{(n)} \in \Omega_n} p(\xi^{(n)} \mid F_X(x)) \tag{5}$$

и

$$p_0(\xi^{(n)}) = \sup_{F_X(x) \in \Omega_0} p(\xi^{(n)}). \tag{6}$$

Тогда статистика отношения правдоподобия Неймана и Пирсона имеет вид

$$\lambda = \frac{p_\omega(\xi^{(n)})}{p_0(\xi^{(n)})}. \tag{7}$$

В непараметрическом случае данная статистика часто теряет смысл. Вольфовиц предложил модификацию этого подхода для двухвыборочного случая, используя исключительно ранговые характеристики наблюдений. Для последовательности перестановок $\xi^{(n)}$ в пространстве B вероятность $p_\omega(\xi^{(n)})$ тождественно равна $1/n!$, а статистика λ становится эквивалентной $p_0(\xi^{(n)})$. Разработанное Вольфовицем приближение для $p_0(\xi^{(n)})$ было предложено в качестве тестовой статистики. Однако при проверке гипотезы случайности H_0 $p_\omega(\xi^{(n)}) = 1/n!$ и $p_0(\xi^{(n)}) \equiv 1$, то есть вероятности принимают постоянные значения, что делает критерий λ тривиальным и непригодным для тестирования.

Ограничим $\xi^{(n)}$ пространством всех возможных последовательностей знаков разностей B^*. Для любой $\xi^{(n)}$ в непараметрическом случае найдется такая функция распределения, что $p_0(\xi^{(n)}) \equiv 1$.

Таким образом, $\lambda = p_\omega(\xi^{(n)})$ и не является константой. Критическая область имеет вид [4]:

$$W_n(B^*) : p_\omega(\xi^{(n)}) \leq c.$$

Рассмотрим пространство статистик B^{**}.

B^{**}: $s_1, s_2, \ldots, s_p, s'_{p+1}, t_1, t_2, \ldots, t_q$. В пределе эти величины имеют совместное многомерное нормальное распределение, поэтому в пределе λ эквивалентно

$$Q(s_1, s_2, \ldots, s_p, s'_{p+1}, t_1, t_2, \ldots, t_q),$$

где для любого набора случайных переменных $x_1, \ldots, x_r$,

$$Q(x_1, \ldots, x_r) = \sum_{i,j=1}^{r} \sigma^{ij}[x_i - E(x_i)][x_j - E(x_j)]$$

с

$$\|\sigma^{ij}\| = \|\sigma_{ij}\|^{-1}.$$

При H_0 критическая область имеет вид

$$W_n(B^{**}) : Q \geq C.$$

Так как $|t-s| \leq 1$, включение t'_{q+1} в B^{**} не нужно, так как в противном случае получится вырожденная матрица $||\sigma_{ij}||$ в пределе [4].

Использование пространства B^{**} менее эффективно, чем B^*, так как теряется информация о порядке появления серий. Однако, использование области $W_n(B^*)$ вычислительно затратно, поэтому можно использовать область $W_n(B^{**})$.

В работе [6] Левене и Вольфовица была дана ковариационная матрица r-статистик. Также в [4] даны ковариационные матрицы s и t статистик. Для проверки корректности расчетов использовались

соотношения типа:

$$\sigma^2(r) = \sigma^2(s_1 + s_2' + t_1 + t_2').$$

Также даны ковариации k, общего числа знаков плюс в B^*, с s_p и s_p'.

При H_0, $\sigma(s_p, k) = -\sigma(t_p, k)$, $\sigma(s_p', k) = -\sigma(t_p', k)$, и $\sigma(r_p, k) = \sigma(r_p', k) = 0$. Также $\sigma(r_p, k) = \sigma(s_p, k) + \sigma(t_p, k)$. Из симметрии следует, что при H_0, $\sigma(t_p, k) = \sigma(s_p, k')$, где k' — общее количество знаков минус в B^*. Следовательно,

$$\sigma(r_p, k) = \sigma(s_p, k) + \sigma(s_p, k') = \sigma(s_p, k + k') = \sigma(s_p, n - 1) = 0,$$

так как $n - 1$ — константа.

Хотя k и не является независимой от $r_1, \ldots, r_p, r_{p+1}'$ при H_0, она некоррелирована с ними. Поскольку k и r-величины имеют совместное нормальное распределение в пределе, следует, что $Q(k)$ и $Q(r_1, \ldots, r_p, r_{p+1}')$ асимптотически независимы и распределены как χ_1^2 и χ_{p+1}^2 соответственно [4].

Статистика λ, зависящая только от k и r, имеет вид [4]:

$$\frac{(k - E(k))^2}{\sigma^2(k)} + \frac{(r - E(r))^2}{\sigma^2(r)} = \chi^2.$$

Построение теста на сериях

H_0 : $(X_1, X_2, ..., X_N)$ - повторная выборка, $F_X(x_1, x_2, ..., x_N) = F_{X_1}(x_1)...F_{X_N}(x_N)$

H_1: выборка не повторная (имеется какая-то закономерность или зависимость)

Тестовая статистика: $Q = \frac{(k-E(k))^2}{\sigma^2(k)} + \frac{(r-E(r))^2}{\sigma^2(r)}$ имеет асимптотически распределение χ_2^2.

При H_0 верны следующие формулы [6]:

$$E(k) = \frac{n-1}{2}, \quad \sigma^2(k) = \frac{n+1}{12}.$$

$$E(r) = \frac{2n-1}{3}, \quad \sigma^2(r) = \frac{16n-29}{90}.$$

Критическая область:

$$Q > \chi^2_{2,1-\alpha},$$

где $\chi^2_{2,1-\alpha}$ — квантиль распределения хи-квадрат с 2 степенями свободы.

Тест серий (правосторонний) на основе статистики Q имеет вид:

$$\varphi(Q) = \begin{cases} 1, & \text{если } Q > \chi^2_{2,1-\alpha}, \\ 0, & \text{иначе.} \end{cases}$$

Алгоритм проверки выборки на повторность, используя тест серий:

1. Посчитать $E(k), E(r), \sigma^2(k), \sigma^2(r)$
2. Вычислить статистику Q
3. Задать уровень значимости α и найти критическое значение $\chi^2_{2,1-\alpha}$
4. Применить тест φ.

1.5 Критерий инверсий

Предполагается, что наблюдения $(X_1, X_2,..., X_n)$ имеют непрерывное распределение. Если гипотеза H_0 верна, то компоненты вектора X равноправны и никак не упорядочены. При отклонениях от гипотезы H_0 данные имеют тот или иной порядок. Значит для проверки H_0 следует основываться на статистике, измеряющей степень "беспорядка"данных [7].

Число инверсий в выборке и является одной из таких статистик.

Статистика T_n — число инверсий в выборке (сумма инверсий для каждого наблюдения).

Крайние случаи, противоречащие гипотезе H_0:

1. $X_1 < X_2 < \cdots < X_n$, тогда $T_n = 0$
2. $X_n < X_{n-1} < \cdots < X_1$, тогда $T_n = \frac{n(n-1)}{2}$

Критерий инверсий:

$$T_{1\alpha} = \left\{ \left| T_n - \frac{n(n-1)}{4} \right| > C_{1-\alpha/2} \right\} \text{— критическая область.}$$

Критическое значение $C_{1-\alpha/2}$ при заданном уровне значимости α выбирают из условия:

$$P_0 \left(\frac{n(n-1)}{4} - C_{1-\alpha/2} \leq T_n \leq \frac{n(n-1)}{4} + C_{1-\alpha/2} \right) \geq 1 - \alpha$$

При $n > 10$ можно использовать нормальное приближение [7]

$$L(T_n|H_0) \approx N(E(T_n), \sigma^2(T_n)),$$

где

$$E(T_n) = \frac{n(n-1)}{4}, \quad \sigma^2(T_n) = \frac{n(n-1)(2n+5)}{72}.$$

Построение критерия инверсий

H_0 : $(X_1, X_2, ..., X_N)$ - повторная выборка, $F_X(x_1, x_2, ..., x_N) = F_{X_1}(x_1)...F_{X_N}(x_N)$

H_1: выборка не повторная (имеется какая-то закономерность или зависимость)

Тестовая статистика: $T_n = \sum_{i=1}^{n} \eta_i$, где η_i - число инверсий, образованных X_i.

Тест (двусторонний) инверсий имеет вид:

$$\varphi(x_1, \ldots, x_n) = \begin{cases} 1, & \text{если } |T_n| > C_{1-\alpha/2}, \\ 0, & \text{если } |T_n| \leq C_{1-\alpha/2}, \end{cases}$$

где:

- T_n - тестовая статистика;

- $C_{1-\alpha/2}$ — критическое значение из таблицы нормального распределения $N(E(T_n), \sigma^2(T_n))$

- α — уровень значимости.

Алгоритм проверки повторности выборки критерием инверсий

1. Вычислить статистику T_n;

2. Задать уровень значимости α и вычислить критическое значение $C_{1-\alpha/2}$;

3. Применить тест φ.

2. ГЛАВА 2. Практическая часть

2.1 Определение альтернатив и генерация данных

Для вычисления мощности тестов предложены альтернативные гипотезы $H_1 - H_6$. Часть из них предполагает наличие линейного тренда, чать периодичности, а также есть альтернатива с положительной автокорреляцией первого порядка.

Для генерации данных при альтернативах H_1, H_2, H_3 использовалась формула:

$$x_i = a \cdot t_i + b \cdot \sin(2k\pi t_i) + \xi_j,$$

где ξ_j представляют собой независимые случайные величины, распределённые по стандартному нормальному закону, $t_i = (i-1)\Delta t$, где $\Delta t = \frac{1}{n}$ (n - объём выборки) [8].

В этом случае справедливой проверяемой гипотезе H_0 соответствует значение параметров $a = 0$, $b = 0$. Отсутствию периодической составляющей соответствует значение параметра $b = 0$, а отсутствию линейной — $a = 0$ [8].

Размеры выборок: 10, 20, 30, 50, 60, 80, 90, 100, 140, 180, 200, 240, 260, 300. Для вычисления мощности теста сгенерировано по 300 выборок каждой размерности.

2.2 Подсчет мощности тестов и ее сравнение

Альтернатива H_1: наблюдения заданы формулой

$$x_i = 4 \cdot t_i + \xi_j,$$

где $t_i = (i-1)\Delta t$, где $\Delta t = \frac{1}{n}$ (n - объём выборки).



Рис. 1: График выборки с линейный трендом

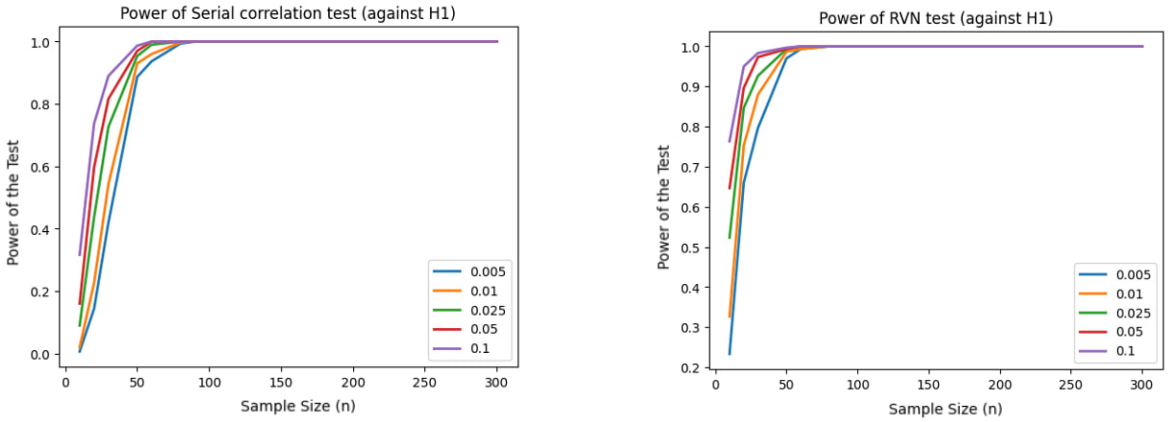


Рис. 2: Мощность теста сериальной корреляции (слева) и RVN теста (справа)

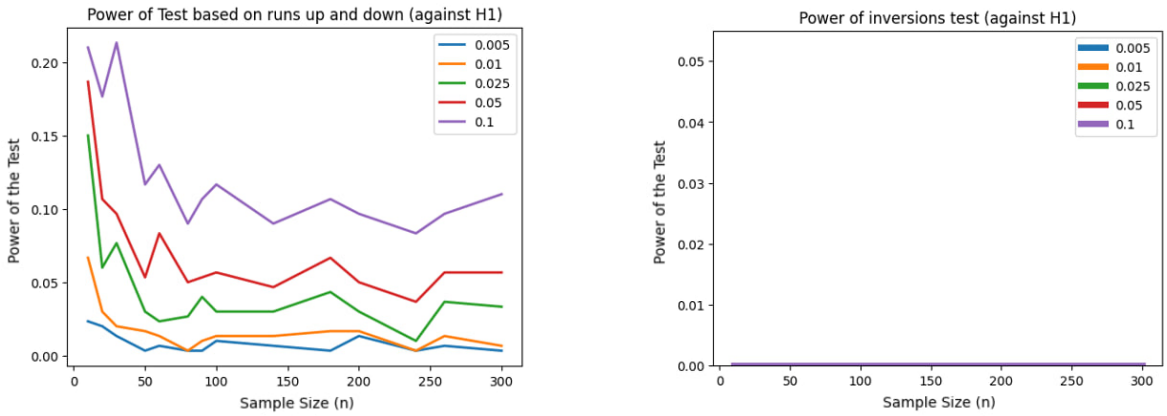


Рис. 3: Мощность теста серий (слева) и критерия инверсий (справа)

Комментарий: на графиках видно, что тест сериальной корреляции и тест RVN лучше распознают линейный тренд в данных, заданных формулой выше. Тест инверсий в данном случае не работает совсем. Тест серий ведет себя странно, его мощность не монотонна при данной альтернативе, а максимальное значение мощности на запущенных данных немного более 0.20, что говорит о плохой способности тестовой процедуры отвергать нулевую гипотезу при верной альтернативе.

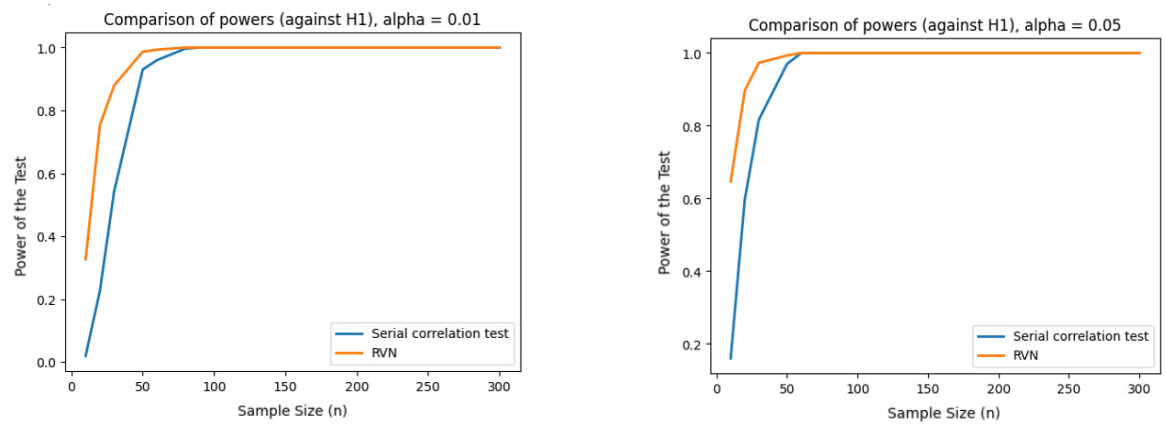


Рис. 4: Сравнение мощностей теста сериальной корреляции и RVN

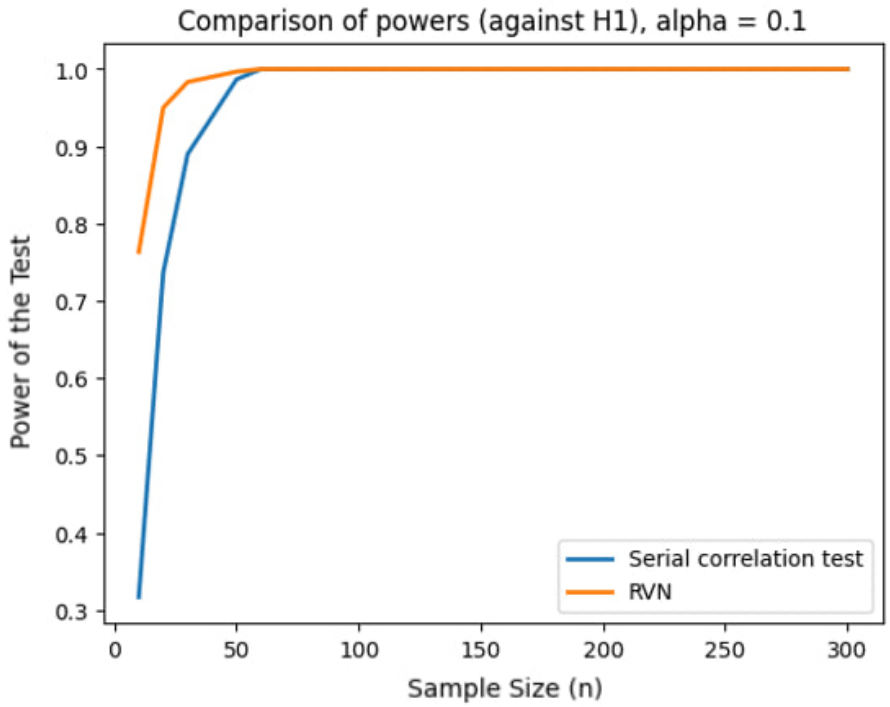


Рис. 5: Сравнение мощностей теста сериальной корреляции и RVN

Комментарий: по графикам видно, что при данной альтернативе ранговый тест RVN работает лучше, чем тест сериальной корреляции. В сравнении не рассмотрены два других теста ввиду очень низких показателей мощности на рис.3.

Альтернатива H_2: наблюдения заданы формулой

$$x_i = 0.5 \cdot \sin(2\pi t_i) + \xi_j,$$

где $t_i = (i-1)\Delta t$, где $\Delta t = \frac{1}{n}$ (n - объём выборки).



Рис. 6: График выборки с периодичностью

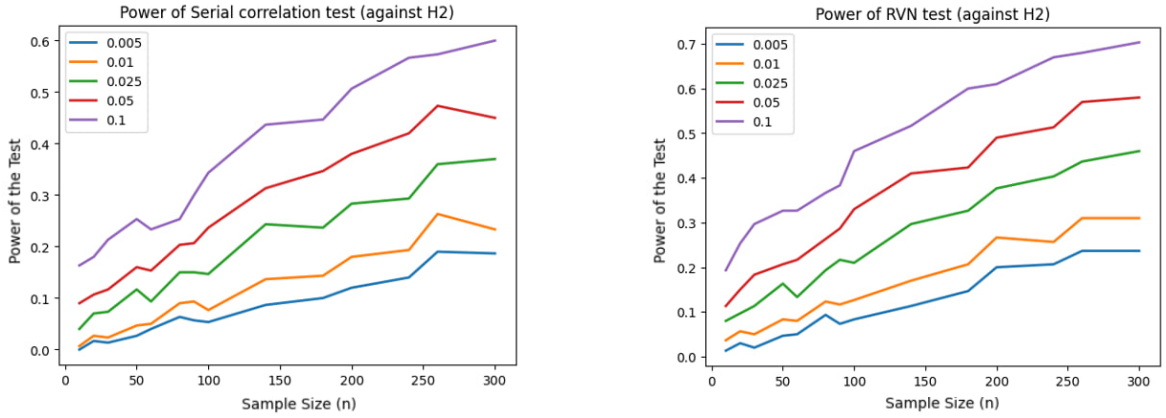


Рис. 7: Мощность теста сериальной корреляции (слева) и RVN теста (справа)

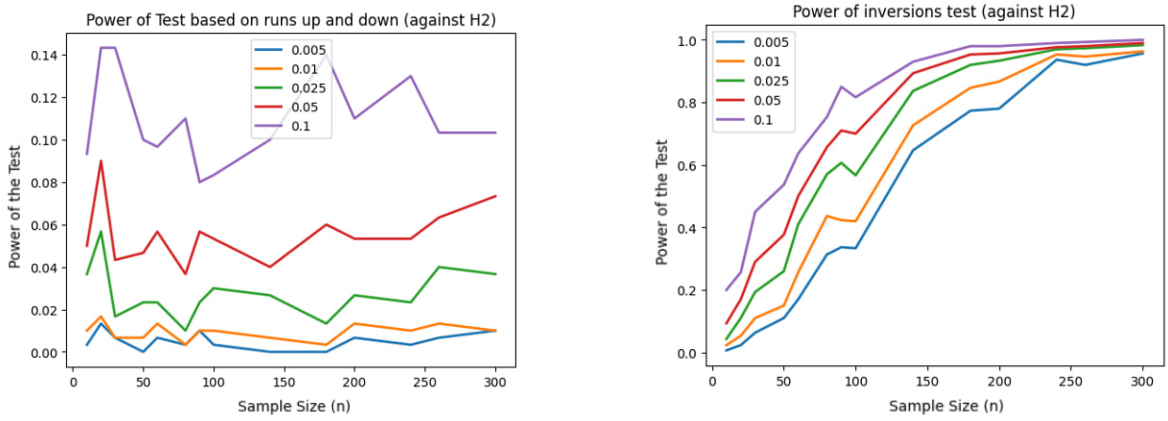


Рис. 8: Мощность теста серий (слева) и критерия инверсий (справа)

Комментарий: С ростом числа наблюдений в выборке мощности теста сериальной корреляции, RVN теста и критерия инверсий в общем возрастают, однако имеются спады при некоторых размерностях выборки. На уровне значимости $\alpha = 0.1$ мощности теста сериальной корреляции и критерия инверсий превышают 0.8 при большом количестве наблюдений. Касательно теста серий, его поведение нестабильно при заданной альтернативе.

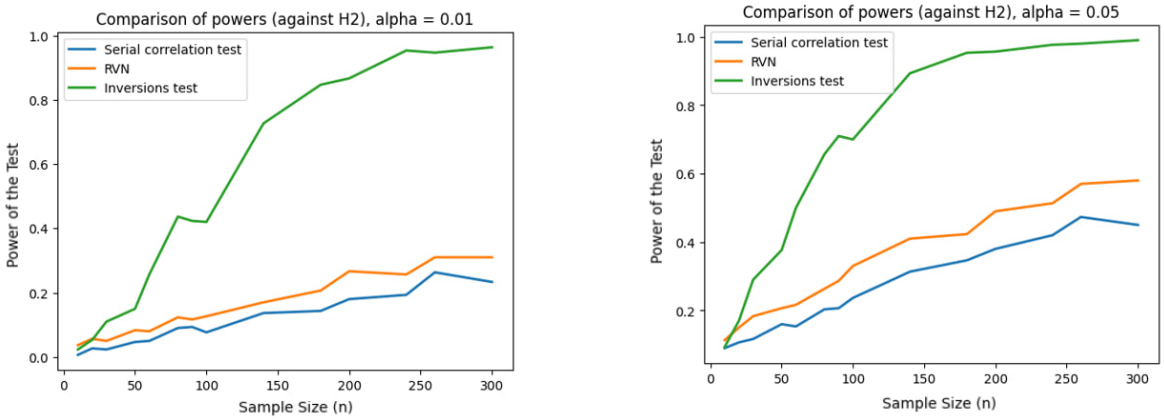


Рис. 9: Сравнение мощностей теста сериальной корреляции, RVN теста и критерия инверсий

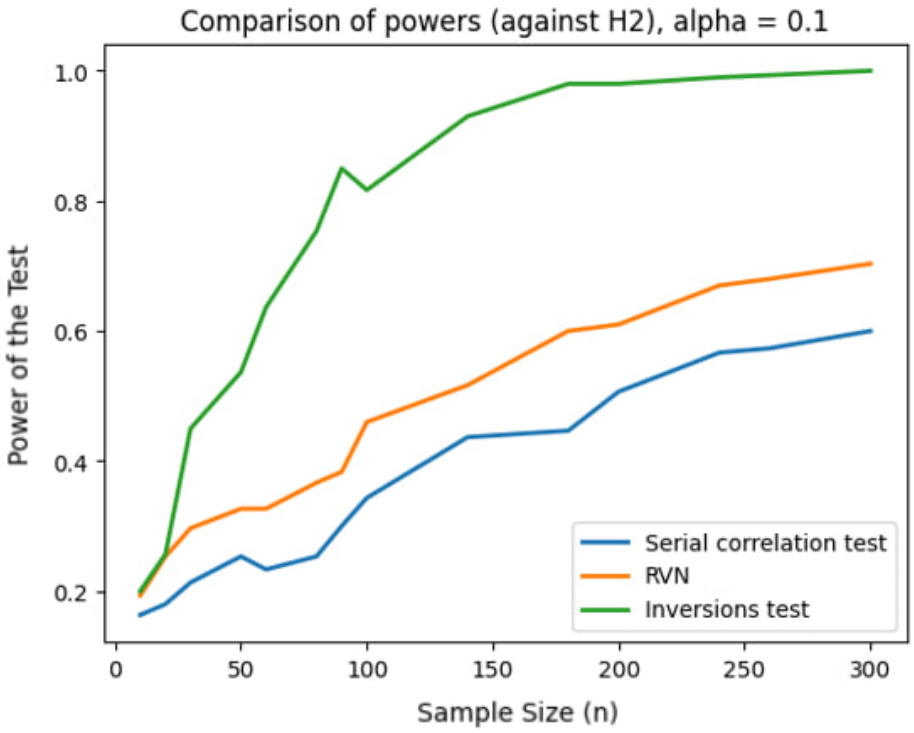


Рис. 10: Сравнение мощностей теста сериальной корреляции, RVN теста и критерия инверсий

Комментарий: по графикам сравнения мощностей можно сказать, что критерий инверсий в данной случае самый мощный против текущей альтернативы. Мощность рангового теста RVN немного лучше мощности теста сериальной корреляции, хотя сильно меньше мощности критерия инверсий. Также можно заметить, что на уровне значимости $\alpha = 0.01$ мощность теста сериальной корреляции и RVN теста мала.

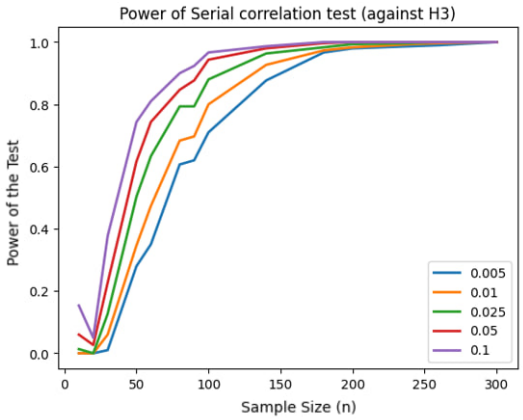
Альтернатива H_3: наблюдения заданы формулой

$$x_i = \sin(2\pi 4 t_i) + \xi_j,$$

где $t_i = (i-1)\Delta t$, где $\Delta t = \frac{1}{n}$ (n - объём выборки).



Рис. 11: График выборки с периодичностью



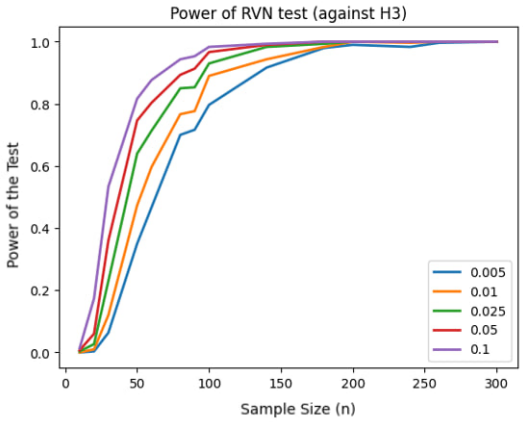
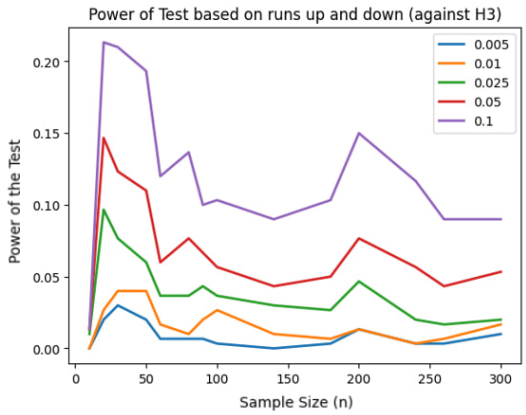


Рис. 12: Мощность теста сериальной корреляции (слева) и RVN теста (справа)



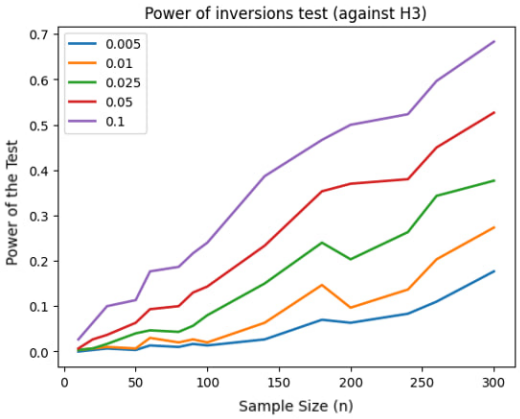


Рис. 13: Мощность теста серий (слева) и критерия инверсий (справа)

Комментарий: мощности тестов сериальной корреляции и RVN возрастают с ростом числа наблюдений в выборке, однако есть нестандартное поведение у мощности теста сериальной корреляции на выборках длины от 10 до 30. Тест на сериях все так же показывает плохие результаты, а поведение мощности нестабильно. Показания мощности критерия инверсий не очень высокие, однако в целом мощность критерия растет.

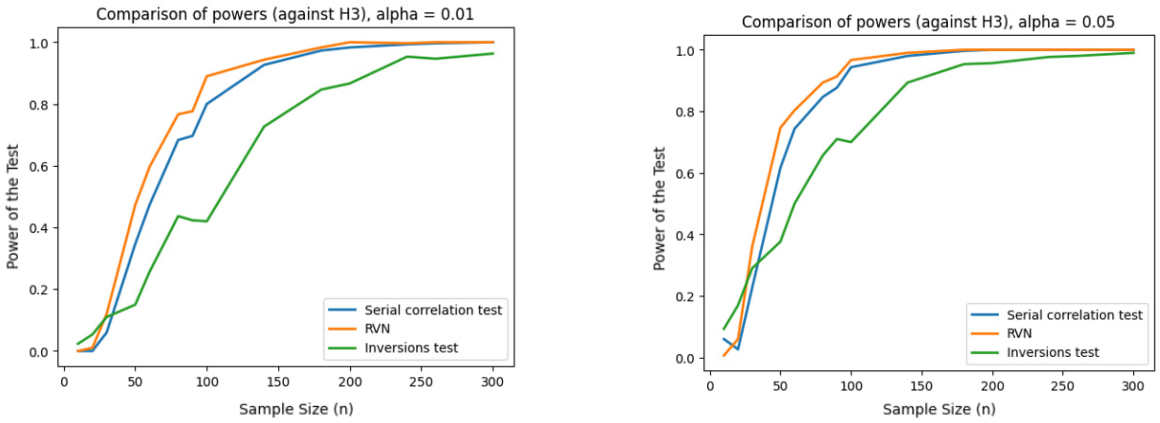


Рис. 14: Сравнение мощностей теста сериальной корреляции, RVN теста и критерия инверсий

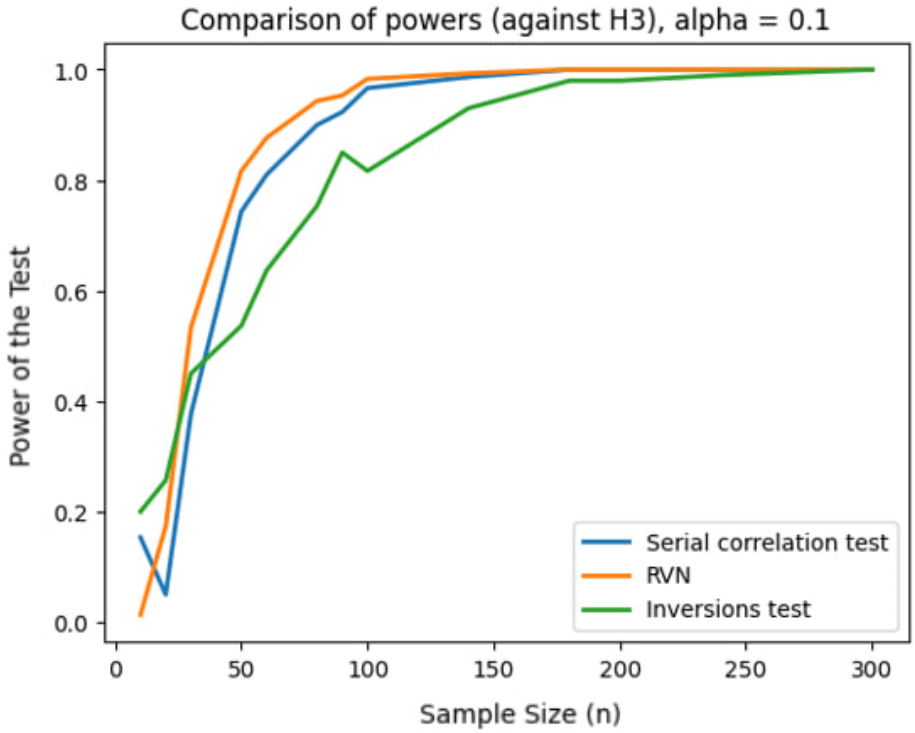


Рис. 15: Сравнение мощностей теста сериальной корреляции, RVN теста и критерия инверсий

Комментарий: по графикам сравнения мощности видно, что ранговый тест и тест сериальной корреляции близки по мощностям на разных уровнях значимости α, но ранговый тест RVN немного мощнее. Критерий инверсий уступает двум вышеупомянутым тестам, хотя тоже имеет достаточно хорошую мощность с ростом размера выборки.

Альтернатива H_4: наблюдения заданы формулой

$$x_i = \xi_i + 0.1 \cdot t_i + c,$$

где $t_i = i$, причем $i = 1, ..., n$ (n - объём выборки), $\xi_i \sim N(0, 1)$, c - константа.



Рис. 16: График выборки с линейным трендом

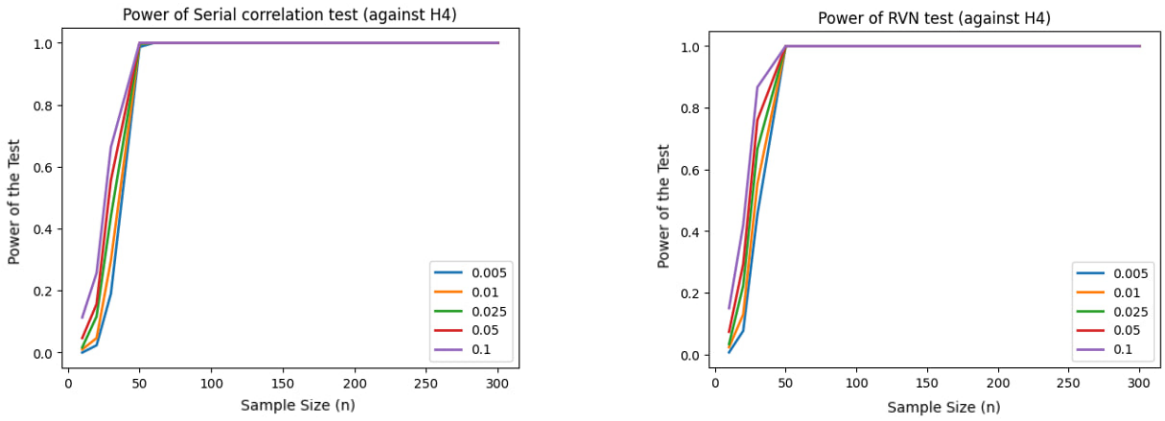


Рис. 17: Мощность теста сериальной корреляции (слева) и RVN теста (справа)

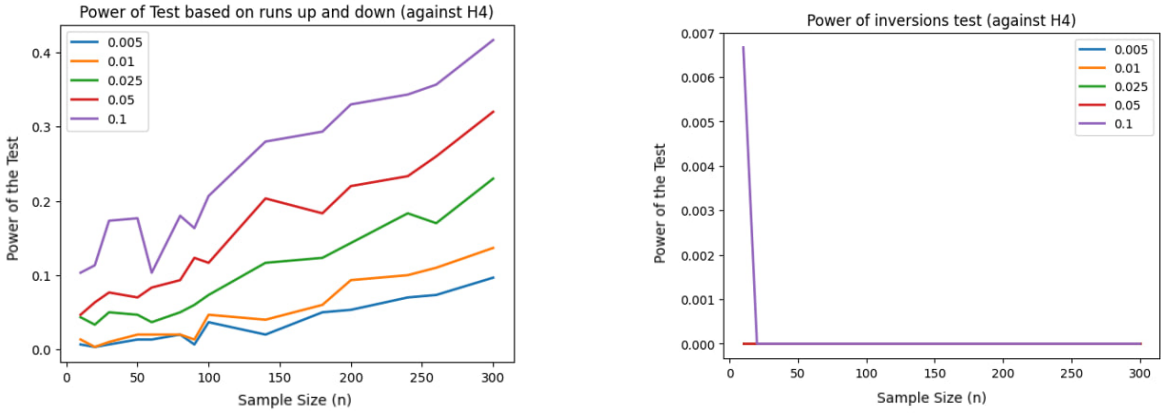


Рис. 18: Мощность теста серий (слева) и критерия инверсий (справа)

Комментарий: мощности тестов сериальной корреляции и RVN монотонно возрастают. При данной альтернативе тест серий ведет себя более стабильно, мощность в целом увеличивается с ростом выборки, хотя на графике и есть спады в некоторых местах. Критерий инверсий является очень слабым при данной альтернативе.

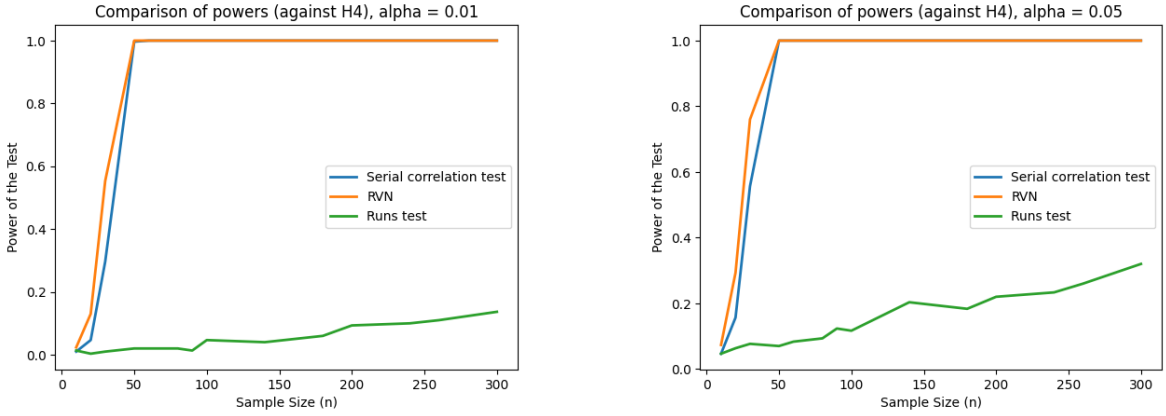


Рис. 19: Сравнение мощностей теста сериальной корреляции, RVN теста и теста серий

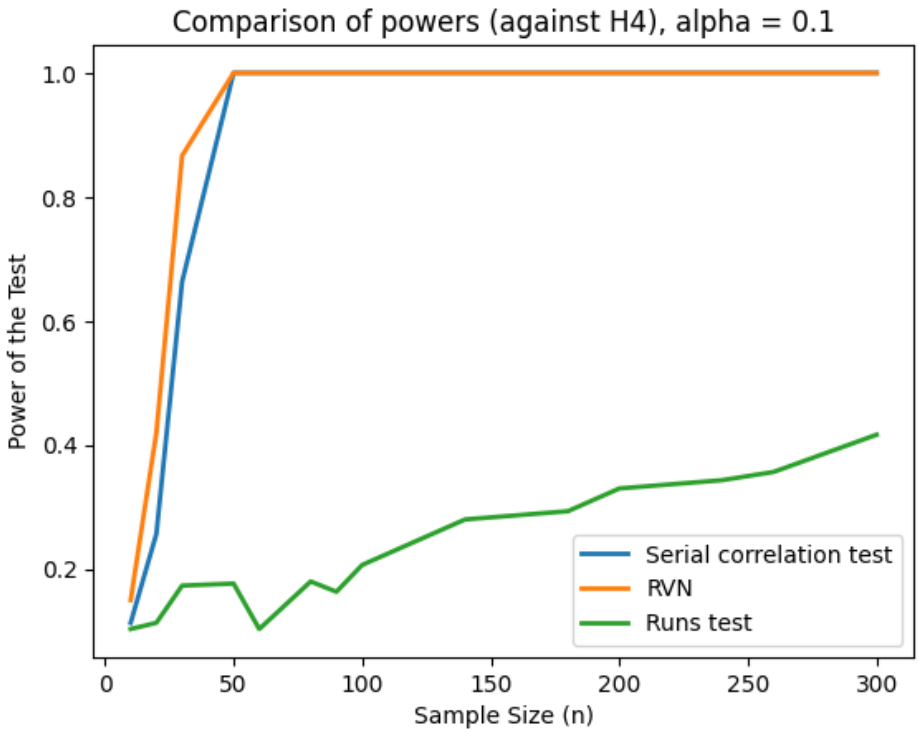


Рис. 20: Сравнение мощностей теста сериальной корреляции, RVN теста и теста серий

Комментарий: на данной альтернативе ранговый тест показывает лучшие результаты по мощности, чем все остальные тесты. Мощности теста RVN и теста сериальной корреляции незначительно различаются, в то время как тест серий имеет гораздо более низкую мощность.

Альтернатива H_5: наблюдения заданы формулой

$$x_i = 3 \cdot \sin(0.2\pi \cdot i) + \varepsilon_i, \quad \text{где } \xi_i \sim N(0,1)$$

где $i = 1, ..., n$ (n - объём выборки).



Рис. 21: График выборки с периодичностью

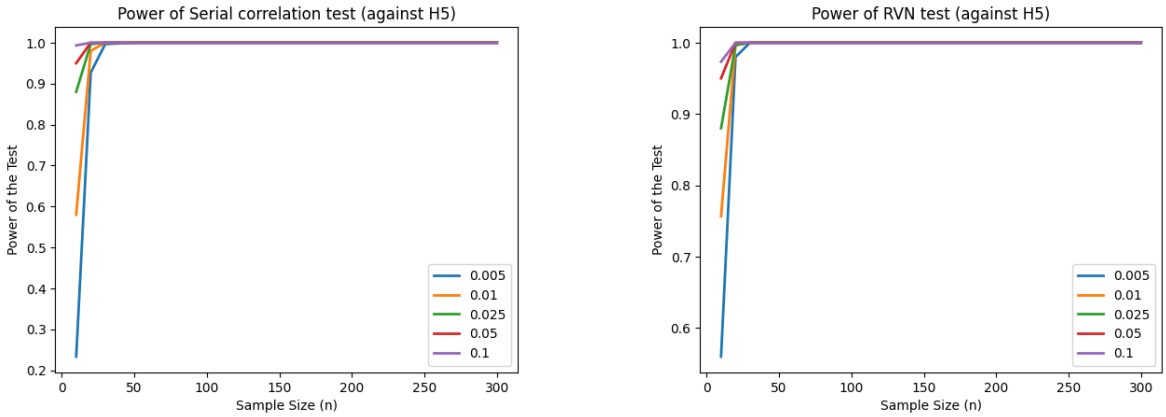


Рис. 22: Мощность теста сериальной корреляции (слева) и RVN теста (справа)

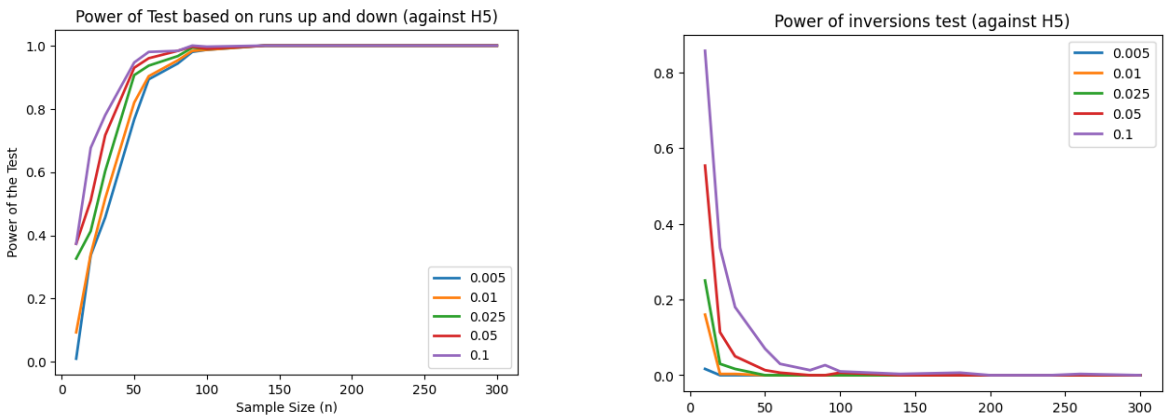


Рис. 23: Мощность теста серий (слева) и критерия инверсий (справа)

Комментарий: тест сериальной корреляции и ранговый тест имеют высокие показатели мощности уже на небольших размерностях выборок. Мощность теста серий при данной альтернативе также достаточно высокая и возрастает с ростом числа наблюдений в выборке. Критерий инверсий при данной альтернативе показывает странные результаты, показатели мощности близки к 0.

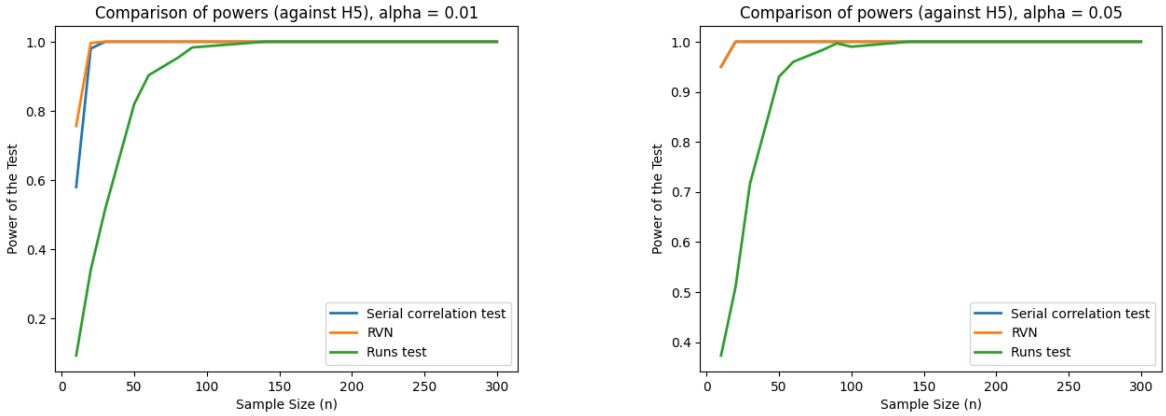


Рис. 24: Сравнение мощностей теста сериальной корреляции, RVN теста и теста серий

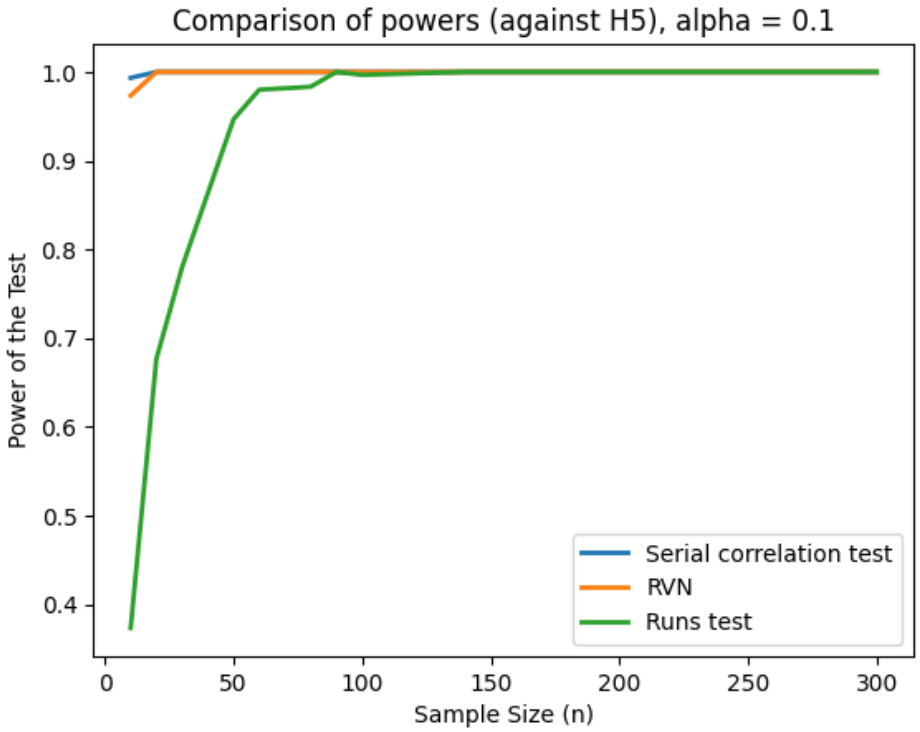


Рис. 25: Сравнение мощностей теста сериальной корреляции, RVN теста и теста серий

Комментарий: на графиках видно, что мощности теста серильной корреляции и RVN теста практически совпадают при указанных уровнях значимости α. Тест серий слабее данных двух, однако все равно имеет высокую мощность наичная с выборок размером больше 50 наблюдений.

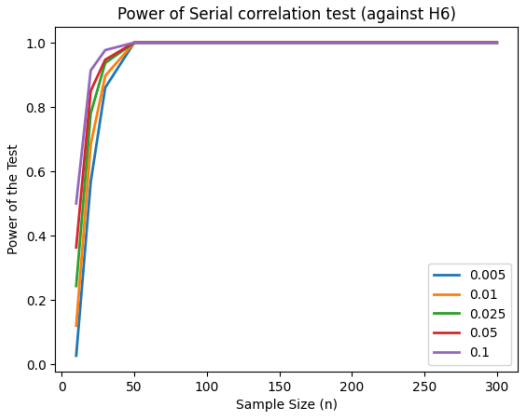
Альтернатива H_6: наблюдения заданы формулой

$$x_i = \phi \cdot x_{i-1} + \xi_i,$$

где ϕ — коэффициент автокорреляции ($0 < \phi < 1$ для положительной автокорреляции), $\xi_i \sim N(0, 1)$.



Рис. 26: График выборки с автокорреляцией



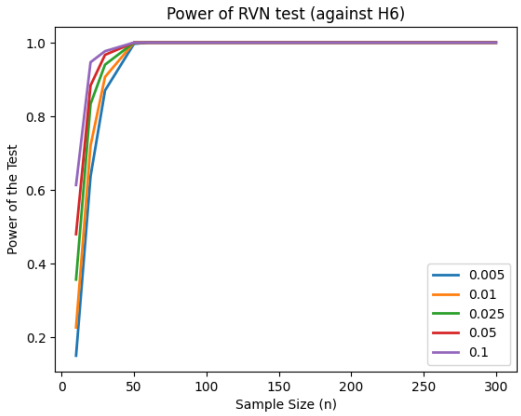
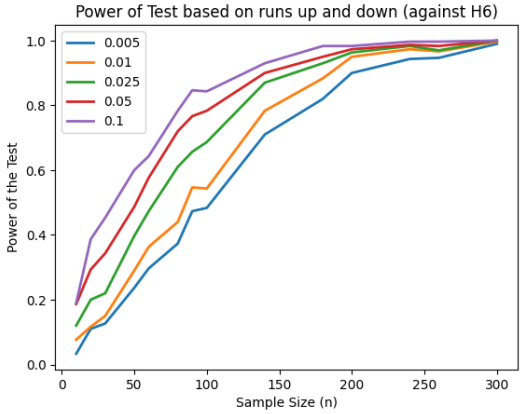


Рис. 27: Мощность теста сериальной корреляции (слева) и RVN теста (справа)



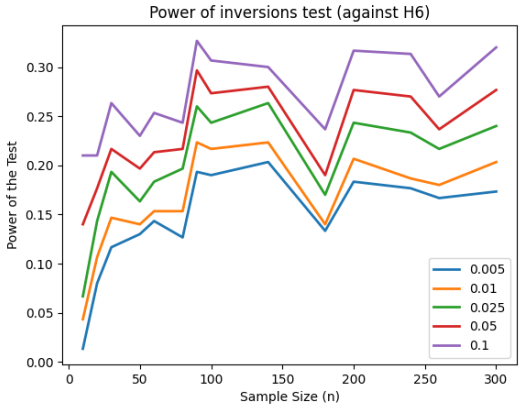


Рис. 28: Мощность теста серий (слева) и критерия инверсий (справа)

Комментарий: все тесты, кроме критерия инверсий, показывают хорошие результаты по мощности при данной альтернативе. Графики теста сериальной корреляции и RVN теста очень похожи. Мощность критерия инверсий ведет себя странно с ростом размера выборки, есть спады мощности в некоторых местах.

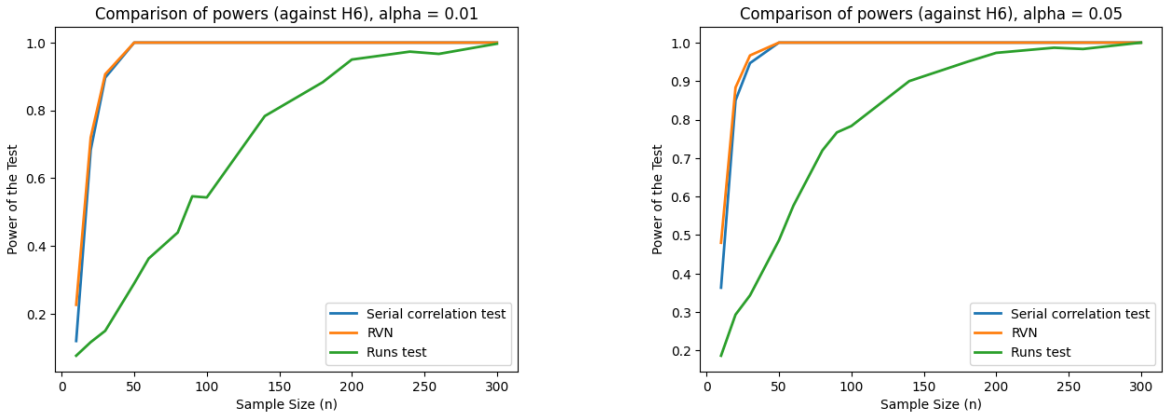


Рис. 29: Сравнение мощностей теста сериальной корреляции, RVN теста и теста серий

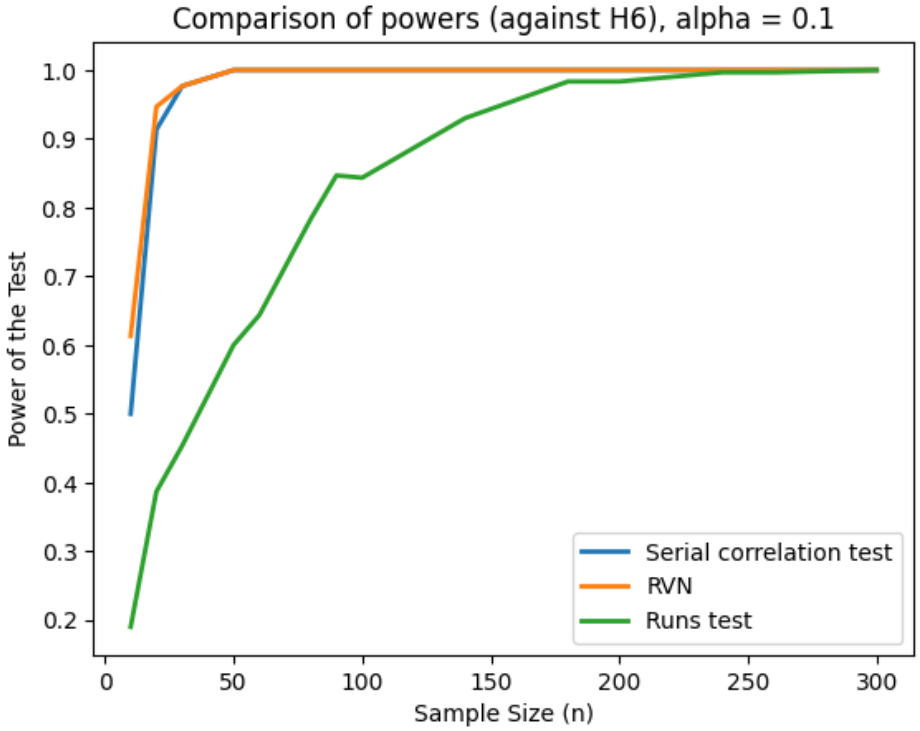


Рис. 30: Сравнение мощностей теста сериальной корреляции, RVN теста и теста серий

Комментарий: Тест сериальной корреляции и RVN тест при данной альтернативе показывают практически одинаково высокие результаты по мощности. Мощность теста серий растет не так быстро, но все же достигает высоких показателей при размере выборки больше 90 наблюдений.

2.3 Применение тестовых процедур на данных фондового рынка

В качестве данных, которые проверяются на повторность, взяты цены акции компании Tesla, Inc. с биржи NASDAQ (тикер TSLA) с помощью python-библиотеки yfinance. Цены берутся с интервалами 1 день, 1.5 часа, 1 час, 30 минут, 1 минута. Всего по 250 наблюдений каждого вида. После подсчета доходностей акции наблюдений стало 249.

Формула для подсчета доходности:

$$R(t) = \ln \frac{P(t)}{P(t-1)},$$

где $R(t)$ — доходность акции за интервал времени в момент t, $P(t)$ — скорректированная цена закрытия акции в момент t;

Все тестовые процедуры, рассмотренные в курсовой работе, с разными заданными уровнями значимости α были применены к данным о доходностях акции.

1. Наблюдения с интервалом 1 день

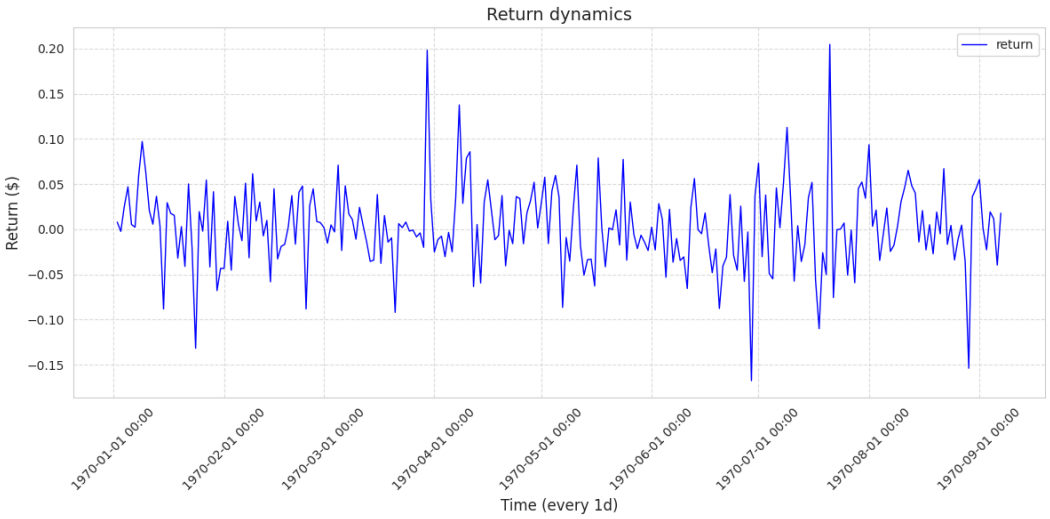


Рис. 31: Доходности акции с интервалом 1 день

Тест	**Уровень значимости α**	**Частота наблюдений**	**Результат**
Сериальная корреляция	0.005	раз в день	да
Сериальная корреляция	0.010	раз в день	да
Сериальная корреляция	0.025	раз в день	да
Сериальная корреляция	0.050	раз в день	да
Сериальная корреляция	0.100	раз в день	да
RVN	0.005	раз в день	да
RVN	0.010	раз в день	да
RVN	0.025	раз в день	да
RVN	0.050	раз в день	да
RVN	0.100	раз в день	да
Тест серий	0.005	раз в день	да
Тест серий	0.010	раз в день	да
Тест серий	0.025	раз в день	да
Тест серий	0.050	раз в день	да
Тест серий	0.100	раз в день	да
Тест инверсий	0.005	раз в день	да
Тест инверсий	0.010	раз в день	да
Тест инверсий	0.025	раз в день	да
Тест инверсий	0.050	раз в день	да
Тест инверсий	0.100	раз в день	да

Таблица 1: Результаты тестов на повторность выборки при частоте наблюдений раз в день

2. Наблюдения с интервалом 1.5 часа

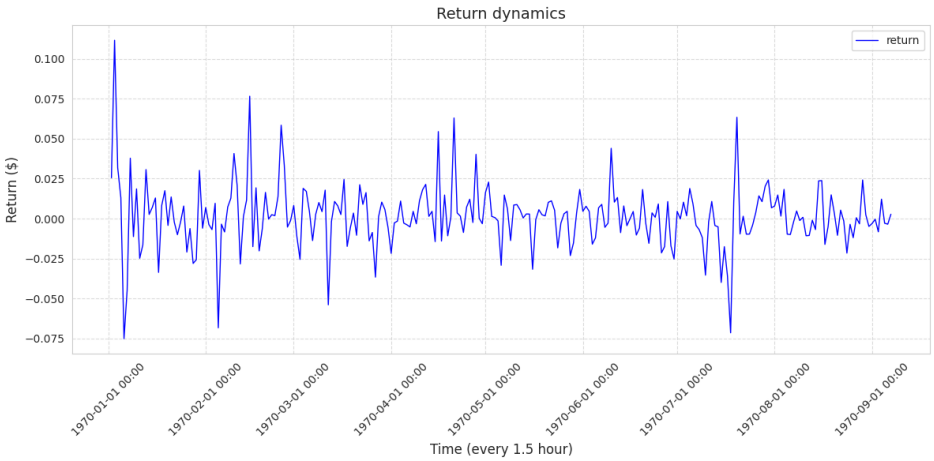


Рис. 32: Доходности акции с интервалом 1.5 часа

Тест	**Уровень значимости α**	**Частота наблюдений**	**Результат**
Сериальная корреляция	0.005	раз в 1.5 часа	да
Сериальная корреляция	0.010	раз в 1.5 часа	да
Сериальная корреляция	0.025	раз в 1.5 часа	да
Сериальная корреляция	0.050	раз в 1.5 часа	да
Сериальная корреляция	0.100	раз в 1.5 часа	нет
RVN	0.005	раз в 1.5 часа	да
RVN	0.010	раз в 1.5 часа	да
RVN	0.025	раз в 1.5 часа	да
RVN	0.050	раз в 1.5 часа	да
RVN	0.100	раз в 1.5 часа	да
Тест серий	0.005	раз в 1.5 часа	да
Тест серий	0.010	раз в 1.5 часа	да
Тест серий	0.025	раз в 1.5 часа	да
Тест серий	0.050	раз в 1.5 часа	да
Тест серий	0.100	раз в 1.5 часа	да
Тест инверсий	0.005	раз в 1.5 часа	да
Тест инверсий	0.010	раз в 1.5 часа	да
Тест инверсий	0.025	раз в 1.5 часа	да
Тест инверсий	0.050	раз в 1.5 часа	да
Тест инверсий	0.100	раз в 1.5 часа	да

Таблица 2: Результаты тестов на повторность выборки при частоте наблюдений раз в 1.5 часа

3. Наблюдения с интервалом 1 час

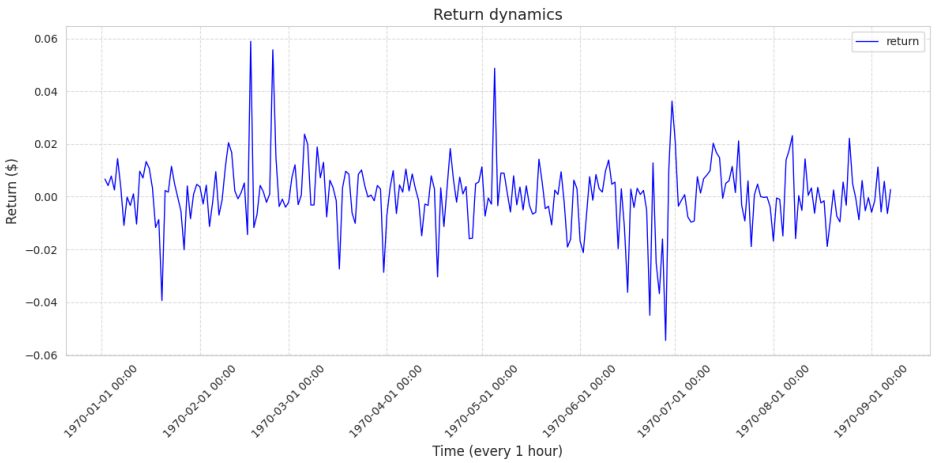


Рис. 33: Доходности акции с интервалом 1 час

Тест	**Уровень значимости α**	**Частота наблюдений**	**Результат**
Сериальная корреляция	0.005	раз в час	да
Сериальная корреляция	0.010	раз в час	да
Сериальная корреляция	0.025	раз в час	да
Сериальная корреляция	0.050	раз в час	нет
Сериальная корреляция	0.100	раз в час	нет
RVN	0.005	раз в час	да
RVN	0.010	раз в час	да
RVN	0.025	раз в час	да
RVN	0.050	раз в час	да
RVN	0.100	раз в час	нет
Тест серий	0.005	раз в час	да
Тест серий	0.010	раз в час	да
Тест серий	0.025	раз в час	да
Тест серий	0.050	раз в час	да
Тест серий	0.100	раз в час	да
Тест инверсий	0.005	раз в час	да
Тест инверсий	0.010	раз в час	да
Тест инверсий	0.025	раз в час	да
Тест инверсий	0.050	раз в час	да
Тест инверсий	0.100	раз в час	да

Таблица 3: Результаты тестов на повторность выборки при частоте наблюдений раз в час

4. Наблюдения с интервалом 30 минут

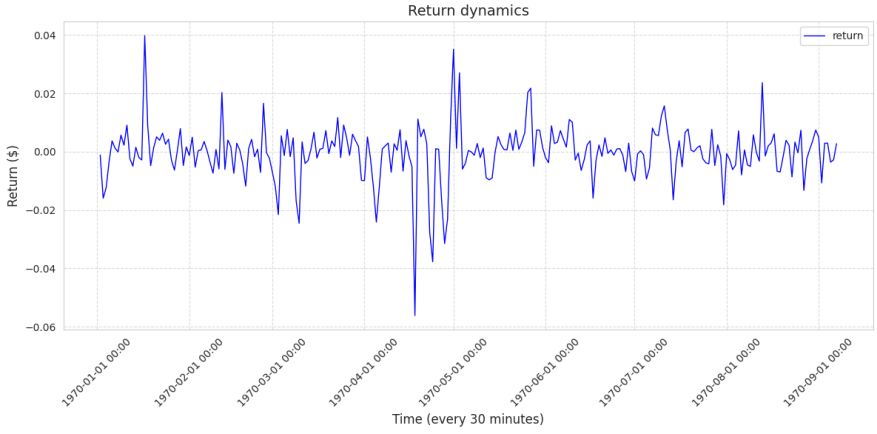


Рис. 34: Доходности акции с интервалом 30 минут

Тест	**Уровень значимости α**	**Частота наблюдений**	**Результат**
Сериальная корреляция	0.005	раз в 30 минут	нет
Сериальная корреляция	0.010	раз в 30 минут	нет
Сериальная корреляция	0.025	раз в 30 минут	нет
Сериальная корреляция	0.050	раз в 30 минут	нет
Сериальная корреляция	0.100	раз в 30 минут	нет
RVN	0.005	раз в 30 минут	да
RVN	0.010	раз в 30 минут	да
RVN	0.025	раз в 30 минут	да
RVN	0.050	раз в 30 минут	нет
RVN	0.100	раз в 30 минут	нет
Тест серий	0.005	раз в 30 минут	да
Тест серий	0.010	раз в 30 минут	да
Тест серий	0.025	раз в 30 минут	да
Тест серий	0.050	раз в 30 минут	да
Тест серий	0.100	раз в 30 минут	да
Тест инверсий	0.005	раз в 30 минут	да
Тест инверсий	0.010	раз в 30 минут	да
Тест инверсий	0.025	раз в 30 минут	да
Тест инверсий	0.050	раз в 30 минут	да
Тест инверсий	0.100	раз в 30 минут	да

Таблица 4: Результаты тестов на повторность выборки при частоте наблюдений раз в 30 минут

5. Наблюдения с интервалом 1 минута

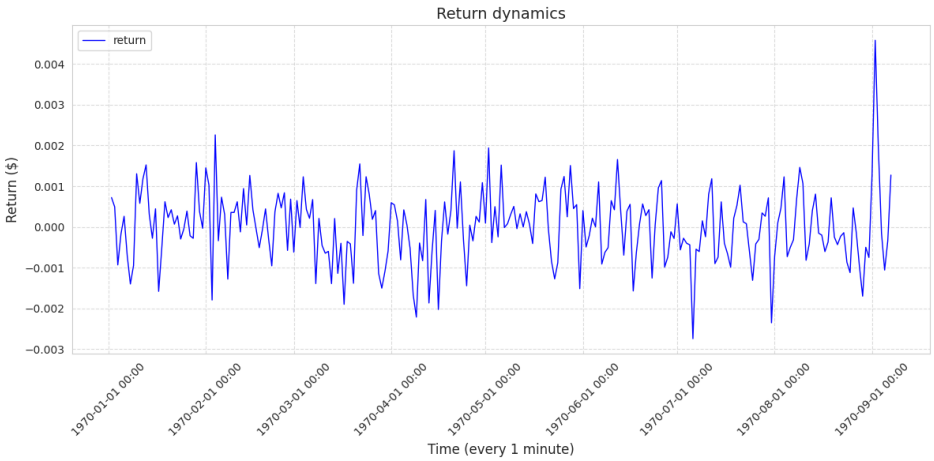


Рис. 35: Доходности акции с интервалом 1 минута

Тест	**Уровень значимости α**	**Частота наблюдений**	**Результат**
Сериальная корреляция	0.005	раз в минуту	нет
Сериальная корреляция	0.010	раз в минуту	нет
Сериальная корреляция	0.025	раз в минуту	нет
Сериальная корреляция	0.050	раз в минуту	нет
Сериальная корреляция	0.100	раз в минуту	нет
RVN	0.005	раз в минуту	нет
RVN	0.010	раз в минуту	нет
RVN	0.025	раз в минуту	нет
RVN	0.050	раз в минуту	нет
RVN	0.100	раз в минуту	нет
Тест серий	0.005	раз в минуту	да
Тест серий	0.010	раз в минуту	да
Тест серий	0.025	раз в минуту	да
Тест серий	0.050	раз в минуту	да
Тест серий	0.100	раз в минуту	да
Тест инверсий	0.005	раз в минуту	да
Тест инверсий	0.010	раз в минуту	да
Тест инверсий	0.025	раз в минуту	да
Тест инверсий	0.050	раз в минуту	да
Тест инверсий	0.100	раз в минуту	да

Таблица 5: Результаты тестов на повторность выборки при частоте наблюдений раз в минуту

Заключение

В ходе выполнения курсовой работы были изучены 4 теста проверки гипотезы о повторности выборки: тест сериальной корреляции, RVN тест (ранговая версия коэффициента фон Неймана), тест серий и критерий инверсий. Все изученные тесты реализованы на языке python, также посчитана мощность тестов при различных альтернативах. Наиболее мощными тестами по результатам практической части оказались ранговый тест и тест сериальной корреляции. Критерий инверсий работает хорошо на малом количестве альтернатив, как и тест серий.

Полученные знания были применены на данных о доходностях акции фондового рынка для определения, являются ли наблюдаемые доходности акции TSLA повторной выборкой. При частоте наблюдений раз в день все тесты определили наблюдаемые доходности как повторную выборку на всех заданных уровнях значимости α. При наблюдениях раз в полтора часа только тест сериальной корреляции на уровне значимости $\alpha = 0.1$ показал, что наблюдения нельзя считать повторной выборкой. Из всех результатов более показательными результатами являются результаты теста сериальной кореляции и RVN теста, так как при большинстве альтернатив они показывали лучшие мощности. Данные тесты показали, что наблюдаемые доходности нельзя считать повторной выборкой на нескольких уровнях значимости α при частоте наблюдений раз в час, раз в 30 минут. При наблюдениях раз в минуту тест сериальной корреляции и ранговый тест на всех уровнях значимости α определили, что данные не являются повторной выборкой. Таким образом, уверенно сказать, что наблюдаемые доходности акции TSLA являются повторной выборкой, можно только при частоте наблюдений раз в день.

Список литературы

1. *Wald A.*, *Wolfowitz J.* An Exact Test for Randomness in the Non-Parametric Case Based on Serial Correlation // The Annals of Mathematical Statistics. — 1943. — Т. 14, № 4. — С. 378—388.
2. *Bartels R.* The Rank Version of von Neumann's Ratio Test for Randomness // Journal of the American Statistical Association. — 1982. — Март. — Т. 77. — С. 40—46.
3. *Rao C. R.* Linear Statistical Inference and Its Applications. — New York : John Wiley, 1965. — 656 с.
4. *Levene H.* On the Power Function of Tests of Randomness Based on Runs up and Down // The Annals of Mathematical Statistics. — 1952. — Т. 23, № 1. — С. 34—56.
5. *Moore G. H.*, *Wallis W. A.* Time series significance tests based on signs of differences // Journal of the American Statistical Association. — 1943. — Т. 38. — С. 153—165.
6. *Levene H.*, *Wolfowitz J.* The covariance matrix of runs up and down // Annals of Mathematical Statistics. — 1944. — Т. 15. — С. 58—69.
7. *Ивченко Г. И.*, *Медведев Ю. И.* Введение в математическую статистику. — Учебник. — М. : Издательство ЛКИ, 2010. — 600 с.
8. *Лемешко Б. Ю.* Критерии проверки гипотез об однородности : Руководство по применению. — М. : Общество с ограниченной ответственностью «Научно-издательский центр ИНФРА-М», 2025. — 248 с.
9. *Колданов А. П.*, *Колданов П. А.* Теория вероятностей и математическая статистика : учебник. — М. : Изд. дом Высшей школы экономики, 2023. — 245 с.

10. *НИУ ВШЭ*. Описательная статистика. — 2017. — URL: http://math-info.hse.ru/f/2017-18/ps-ms/descriptives.pdf (дата обр. 05.04.2025).

Приложение

Код на Python для выполнения практической части можно найти по ссылке: https://colab.research.google.com/drive/1q6okXIcGkCmPIToTAU0iu3shC2bENayR